Citadel

Chat con IA local para Windows · versión 1.2.0 · github.com/Gabriel-Castiglia/citadel-windows

Gabriel Castiglia · 10 de noviembre de 2026 · versión 1.2.0 · licencia GPL-2.0

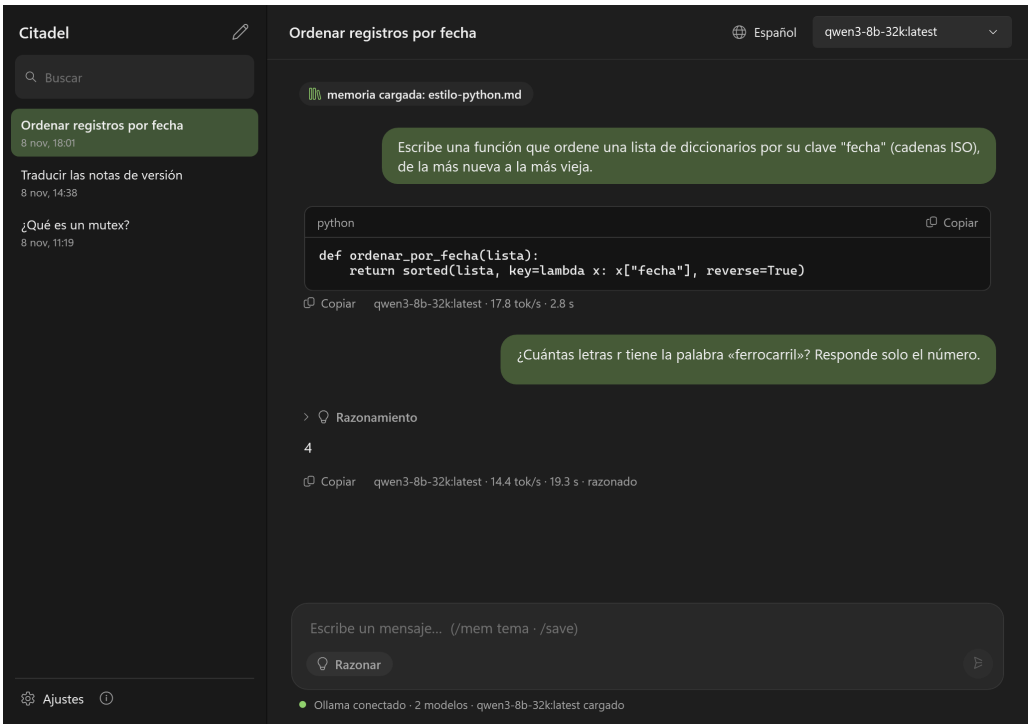
English · Español

Repositorio: https://github.com/Gabriel-Castiglia/citadel-windows

Manual en PDF: `docs/Citadel-manual-es.pdf`

Citadel es una app de chat para Windows 10 y 11 que conversa con modelos de lenguaje que corren en la misma computadora mediante Ollama. Nada de lo que escribes sale de la computadora: la app solo se conecta con Ollama en `127.0.0.1:11434`, salvo que elijas usar el Ollama de otra computadora tuya por SSH (ver Ollama en otra computadora). Está escrita en C# con .NET 10 y WPF, usa el estilo de Windows 11, oscuro, claro o como Windows, en uno de doce colores, y su interfaz está en inglés y en español. La versión para macOS, con las mismas funciones, tiene su propio repositorio: https://github.com/Gabriel-Castiglia/citadel.

Citadel es una ventana de chat, no un agente. El modelo no puede abrir archivos, ejecutar comandos ni navegar por la web. Recibe lo que escribes, los archivos de texto que adjuntas, unas reglas que van con cada pedido y, cuando lo pides, una de tus memorias guardadas.



Requisitos

- Windows 11, o Windows 10 versión 1803 o posterior, de 64 bits.

- Ollama para Windows, desde https://ollama.com/download. Su instalador lo deja funcionando en segundo plano y arrancando con Windows. Después se descarga un modelo, en PowerShell:

  ```
  ollama pull qwen3:8b
  ```

Citadel arranca con el modelo `qwen3-8b-32k:latest` elegido si está instalado y, si no, con el primero que liste Ollama. Ese nombre es Qwen3 8B con un contexto de 32.768 tokens, creado así:

```
Set-Content Modelfile "FROM qwen3:8b`nPARAMETER num_ctx 32768"
ollama create qwen3-8b-32k -f Modelfile
```

Qwen3 8B necesita unos 7 GB de memoria mientras está cargado. La velocidad de las respuestas depende de la tarjeta gráfica: sin una que Ollama admita, el modelo corre en el procesador y contesta mucho más despacio.

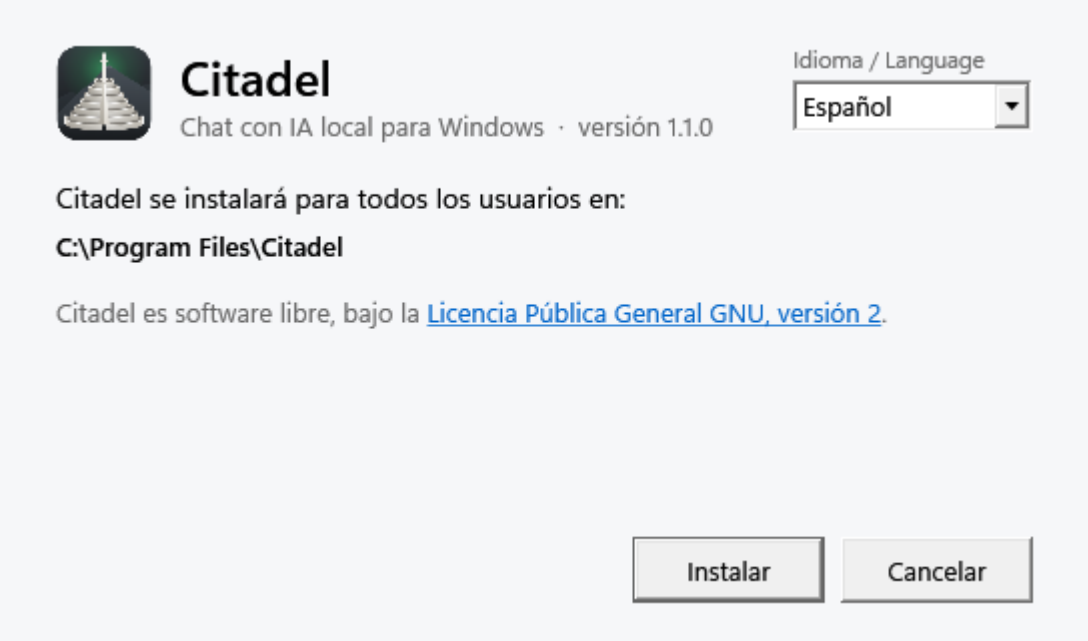
No hace falta instalar nada más. Citadel trae su propio entorno de .NET, y la ventana de instalación usa el .NET Framework que Windows ya incluye.

Instalación

Hay tres formas de obtener Citadel; las tres las genera `scripts\build.ps1` en la carpeta `dist`:

Archivo	Qué es
`citadel-setup.exe`	Programa de instalación, en inglés o en español. La forma habitual de instalar.
`citadel.msi`	La misma instalación como paquete de Windows Installer, para instalar sin ventanas: `msiexec /i citadel.msi /qn`.
`Citadel.exe`	El programa solo; funciona sin instalar desde cualquier carpeta.

El programa de instalación abre una ventana con un menú de idioma arriba a la derecha, y cada página cambia de idioma al instante. Instala Citadel para todos los usuarios en `C:\Program Files\Citadel`, lo que requiere permisos de administrador (Windows los pide al empezar la instalación), y agrega Citadel al menú Inicio. El idioma elegido en la ventana de instalación es el que Citadel usa la primera vez que arranca.



Ejecutar un `citadel-setup.exe` más nuevo actualiza el Citadel instalado y conserva las conversaciones, las memorias y los ajustes de cada usuario. Si Citadel está abierto, la instalación lo cierra antes de reemplazar sus archivos. Una versión más vieja no se puede instalar encima de una más nueva.

Los archivos no están firmados con un certificado comercial, así que la primera vez Windows SmartScreen puede mostrar «Windows protegió su PC». «Más información» → «Ejecutar de todas formas» los abre.

Desinstalación

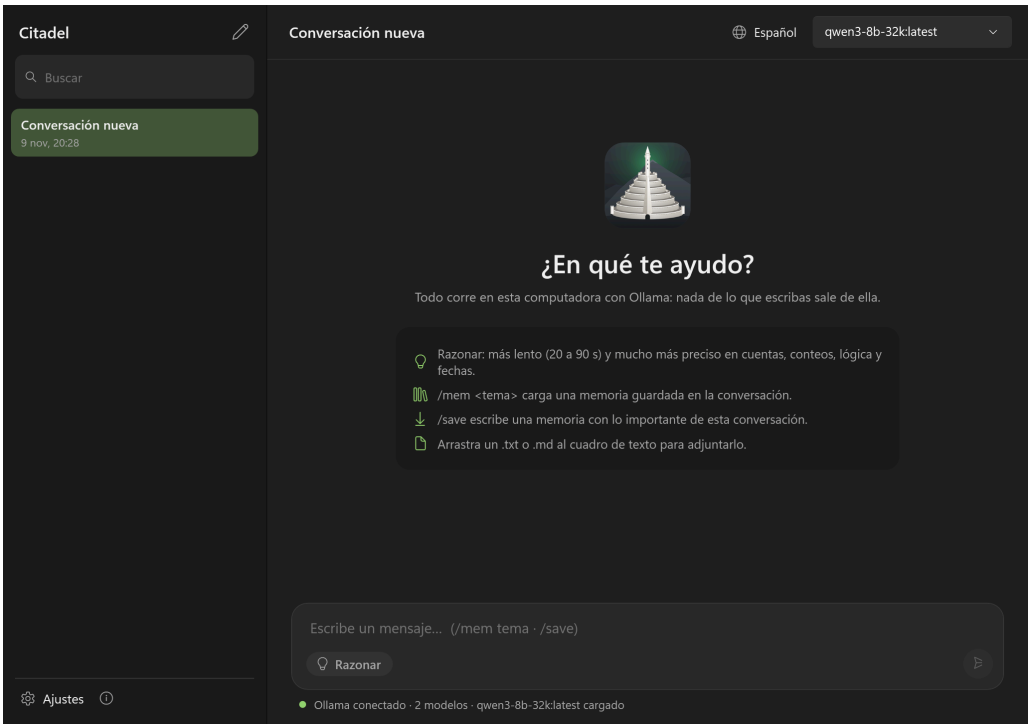
Abre Configuración de Windows → Aplicaciones → Aplicaciones instaladas, busca Citadel y elige Desinstalar. Se abre la misma ventana de instalación, con su menú de idioma. Cierra Citadel si está abierto y quita el programa y el acceso del menú Inicio.

Los datos de cada usuario, en `%APPDATA%\Citadel`, se conservan, así una instalación posterior los encuentra. Para borrarlos también, elimina esa carpeta.

Para desinstalar sin ventanas: `citadel-setup.exe /uninstall /quiet`.



Uso



Escribe en el cuadro de abajo y pulsa Enter para enviar. Shift+Enter (o Alt+Enter) empieza una línea nueva. La respuesta aparece a medida que se escribe, con formato Markdown: títulos, listas, tablas, citas, negrita, código en línea y bloques de código en un recuadro de letra monoespaciada con su propio botón Copiar. La respuesta entera se puede seleccionar con el mouse. Debajo de cada respuesta están el botón Copiar de la respuesta entera, el modelo, su velocidad en tokens por segundo y los segundos que tardó.

Conversaciones

La barra lateral lista las conversaciones, de la más nueva a la más vieja. Ctrl+N o el botón del lápiz empiezan una nueva, cuyo título es la primera línea del primer mensaje. Con clic derecho sobre una conversación se la renombra o se la elimina; eliminar pide confirmación y borra su archivo del disco. El campo de búsqueda filtra por título sin distinguir mayúsculas ni tildes.

Modelos

La lista de modelos, arriba a la derecha, muestra todos los modelos instalados en Ollama y los vuelve a leer cada vez que se abre; eliges uno y el próximo mensaje va a ese. La elección se recuerda, y debajo de cada respuesta figura el modelo que la escribió, así que en una misma conversación se pueden comparar varios. Para agregar un modelo, instálalo desde una terminal y vuelve a abrir la lista:

```
ollama pull gemma3:12b
```

Sirve cualquier modelo de chat de la biblioteca de Ollama. Los modelos que no pueden razonar (Ollama no incluye «thinking» entre sus capacidades) aparecen en la lista con «(sin Razonar)», y con uno de ellos elegido el botón Razonar queda atenuado y su ayuda dice por qué. Citadel le pregunta a Ollama las capacidades de cada modelo al listarlos, así que un modelo nuevo queda clasificado en cuanto aparece.

Ollama le da a cada modelo una ventana de contexto de unos pocos miles de tokens, salvo que el modelo indique otra. Para conversaciones largas o adjuntos grandes, crea una variante con una ventana mayor, como en Requisitos, y elígela en la lista. Una ventana mayor ocupa más memoria.

Estado

La línea bajo el cuadro de texto dice si Ollama responde y dónde (en esta computadora, o en otra por SSH), si el modelo está cargado o se cargará con el próximo mensaje, qué está haciendo (cargando, razonando, escribiendo) con los segundos transcurridos, y la velocidad de la última respuesta. Cuando Ollama no responde, esa misma línea dice cómo iniciarlo, o da el error de SSH.

Razonar

El botón Razonar hace que el modelo piense antes de contestar; mientras está activo se llena con el color de énfasis. El razonamiento va en un bloque atenuado sobre la respuesta. El bloque queda plegado, mostrando la última línea mientras el modelo piensa, y se abre con un clic. Razonar es más lento y mucho más preciso en cuentas, conteos de letras o palabras, lógica y fechas. Sin razonar, el modelo contesta enseguida y alcanza para explicaciones, redacción, traducción y código. Razonar solo está disponible con los modelos que saben razonar (ver Modelos).

Con Razonar activo, una respuesta puede escribir hasta 8.000 tokens; sin él, hasta 3.000. En Notas técnicas están las mediciones que llevaron a esos valores.

Detener

Mientras se escribe una respuesta, el botón de enviar pasa a ser Detener (también Esc). Cierra la conexión y Ollama deja de generar; lo escrito hasta ese momento queda, marcado como «Detenido».

Adjuntos

Arrastra un archivo `.txt` o `.md` al cuadro de texto para adjuntar su texto al próximo mensaje; una etiqueta muestra el nombre del archivo y su largo, con un botón para quitarlo.

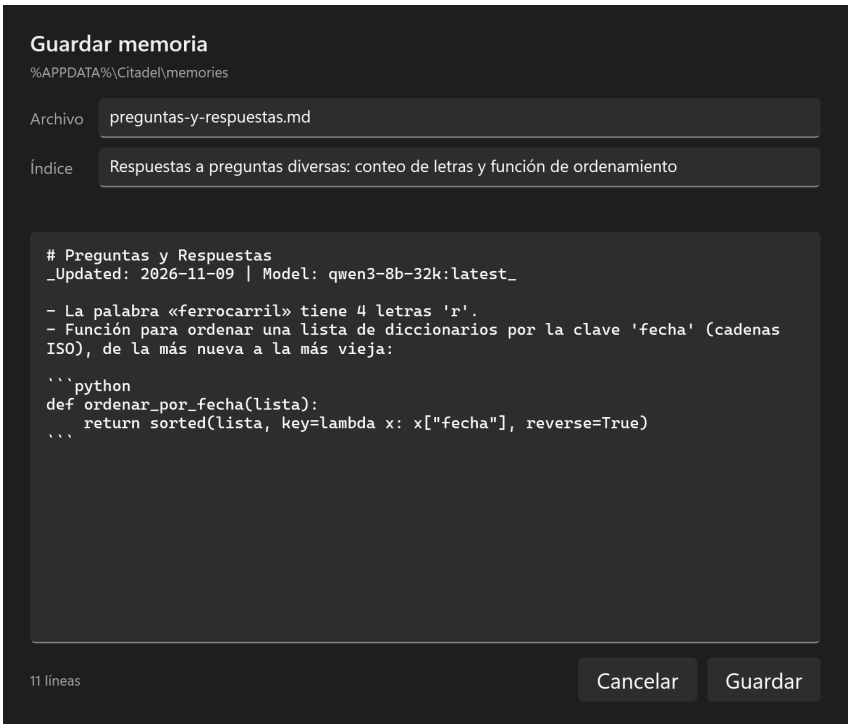
Memorias

Una memoria es un archivo Markdown breve en la carpeta de memorias, listado en el `_index.md` de esa carpeta con una línea por memoria:

```
`viaje-a-kioto.md` — Viaje a Kioto en marzo: fechas y reservas
```

El índice va con cada pedido, así el modelo sabe qué memorias existen. Su contenido no va, hasta que cargas una:

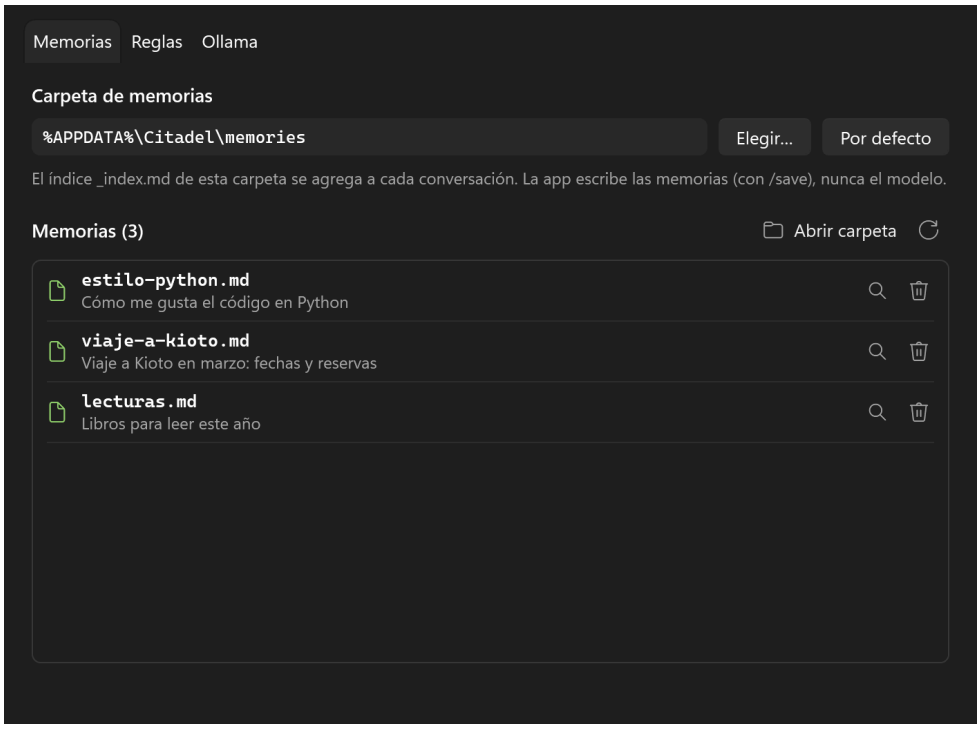
- `/mem <tema>` busca la memoria cuya línea del índice o nombre de archivo comparte más palabras con el tema (sin distinguir tildes ni mayúsculas) y la agrega a la conversación. Una etiqueta muestra «memoria cargada:» y el nombre del archivo. Si nada coincide, Citadel lo dice.
- `/save` le pide al modelo que escriba una memoria con la conversación actual: un título, la línea `_Updated: AAAA-MM-DD | Model: <modelo>_` y los datos que vale la pena guardar, en el idioma de la conversación. Se abre una vista previa donde se pueden corregir el nombre del archivo, la línea del índice y el texto. Si el archivo ya existe, la vista previa avisa que se va a reemplazar. Guardar escribe el archivo y su línea del índice, los vuelve a leer del disco y solo entonces lo confirma en la conversación.



Las memorias las escribe Citadel, no el modelo. Los modelos locales chicos suelen contestar «guardado» sin guardar nada; por eso el modelo solo redacta el texto, y la app escribe el archivo y lo comprueba.

Ajustes

El botón Ajustes, abajo en la barra lateral (o Ctrl+,), abre una ventana con tres pestañas.



Pestaña	Qué contiene
Memorias	La carpeta de memorias (Elegir…, o Por defecto para volver a `%APPDATA%\Citadel\memories`), la lista de memorias con su línea del índice, Abrir carpeta, Mostrar en el Explorador para cada memoria, y Eliminar, que pide confirmación y borra el archivo y su línea del índice.
Reglas	Las reglas que van al principio de cada pedido, editables. Guardar (Ctrl+S) las escribe; Descartar cambios deshace lo editado; Restaurar las originales vuelve a las reglas de fábrica.
Ollama	Dónde corre Ollama: en esta computadora, o en otra por SSH (ver Ollama en otra computadora). Aplicar y probar se conecta enseguida y lista los modelos que encuentra.

Cualquier carpeta puede ser la carpeta de memorias, también una que use otra herramienta, mientras mantenga el mismo formato de `_index.md`.

Reglas

Cada pedido empieza con un mensaje de sistema formado por el archivo de reglas, el índice de memorias y las memorias cargadas con `/mem`. El archivo de reglas es `%APPDATA%\Citadel\rules.md` y se crea en el primer arranque con estas reglas (en inglés, que es como mejor las siguen los modelos chicos):

1. Contestar en el idioma del usuario y exactamente lo que se pidió; si solo se pide el resultado, dar solo el resultado.
2. No inventar: si no sabe la respuesta, si es posterior a sus datos de entrenamiento, si es privada o trata de algo que quizá no existe, decirlo en una oración.

3. Revisar la premisa y avisar primero si es falsa.
4. Formatos exactos: solo JSON, solo una lista o exactamente N elementos quiere decir exactamente eso.
5. Código: un bloque de código Markdown cercado con la función completa, sin `input()` ni llamadas de ejemplo.
6. Traducción: dejar sin cambios el texto entre comillas invertidas, las rutas, los comandos, los números y los nombres, y contestar solo con la traducción.
7. El modelo corre localmente con Ollama y nada sale de la computadora.

La última regla está porque un modelo local, cuando se le pregunta dónde corre, tiende a contestar que en la nube, cosa que no puede saber.

Idioma

La interfaz está en inglés y en español. El botón del globo, arriba a la derecha junto a la lista de modelos, muestra el idioma actual y abre el menú de idioma; el cambio se aplica al instante y se recuerda. En el primer arranque Citadel usa el idioma elegido durante la instalación, o inglés cuando corre sin instalar. El idioma de la interfaz no cambia el de las respuestas: el modelo contesta en el idioma en que le escribes.

Tema y color

Ajustes → Apariencia elige cómo se ve la ventana: como Windows (clara u oscura, como tus otras apps), clara u oscura, que es la de fábrica. Debajo, doce colores cambian los botones, la selección y el resplandor detrás de la ciudadela en el ícono de la ventana y de la barra de tareas mientras Citadel está abierto; el verde es el original. Los accesos directos del menú Inicio y del escritorio conservan el ícono verde. La versión para Mac tiene las mismas opciones.

Ollama en otra computadora

Un modelo demasiado grande para esta computadora puede correr en otra computadora tuya, y Citadel puede usarlo por SSH. Citadel abre el comando `ssh` que trae Windows, con un túnel desde un puerto local libre hasta el puerto 11434 de esa computadora, manda cada pedido por ahí y lo cierra al salir. El puerto de Ollama nunca se abre a la red: a la otra computadora solo le hace falta aceptar SSH. Las conversaciones, las reglas y las memorias se quedan en esta computadora; la otra recibe cada pedido cuando se envía, como pasa siempre con Ollama.

En la computadora que corre el modelo:

1. Instala Ollama y los modelos, como en Requisitos. A Ollama le basta escuchar en `127.0.0.1`, que es lo que hace de fábrica.

2. Enciende el servidor SSH: en una Mac, Ajustes del Sistema → General → Compartir → Sesión remota; en Windows, Configuración → Sistema → Características opcionales → Servidor OpenSSH, y después inicia el servicio `sshd`.

3. Autoriza la llave pública de esta computadora (`%USERPROFILE%\.ssh\id_ed25519.pub`; si no existe, créala con `ssh-keygen -t ed25519`). En el `~/.ssh/authorized_keys` del usuario de la otra computadora, una línea como esta deja que esa llave reenvíe el puerto de Ollama y nada más (ni terminal, ni comandos, ni otros puertos):

   ```
   restrict,port-forwarding,permitopen="127.0.0.1:11434",command="/usr/bin/false" s
   sh-ed25519 AAAA… nombre
   ```

   En un servidor Windows ese archivo es `C:\Users\<usuario>\.ssh\authorized_keys` para un usuario estándar, o `C:\ProgramData\ssh\administrators_authorized_keys` para un administrador, y el comando forzado es `command="cmd /c exit"`.

En esta computadora, abre Ajustes → Ollama, elige «En otra computadora, por SSH», escribe el destino (`usuario@equipo`, o un nombre `Host` de `%USERPROFILE%\.ssh\config`) y haz clic en Aplicar y probar. La línea de resultado lista los modelos que hay allá, y la línea de estado bajo el cuadro de texto dice «Ollama en (SSH)». Citadel nunca pide contraseña (corre ssh en modo por lotes), así que la llave tiene que funcionar sin una o estar cargada en el agente de OpenSSH. La primera conexión a un equipo nuevo guarda su llave en `known_hosts`; si esa llave cambia después, la conexión falla, como en cualquier cliente SSH. Si la conexión se corta, Citadel la vuelve a abrir con el pedido siguiente.

Teclado

Teclas	Acción
Enter	Enviar
Shift+Enter, Alt+Enter	Línea nueva
Ctrl+N	Conversación nueva
Esc	Detener la respuesta
Ctrl+,	Ajustes
Ctrl+S	Guardar las reglas (pestaña Reglas)

Archivos

Qué	Dónde
Programa instalado	`C:\Program Files\Citadel`, con `LICENSE.txt`, `README.txt` y `README.es.txt`
Conversaciones	`%APPDATA%\Citadel\conversations\`, un archivo JSON cada una
Reglas	`%APPDATA%\Citadel\rules.md`
Memorias (carpeta por defecto)	`%APPDATA%\Citadel\memories\`, con `_index.md`
Ajustes (idioma, modelo, Razonar, carpeta de memorias, destino SSH, posición de la ventana)	`%APPDATA%\Citadel\settings.json`
Registro de errores, si algo falla	`%APPDATA%\Citadel\citadel.log`, de menos de 512 KB

Los archivos se escriben en UTF-8 sin marca de orden de bytes. Las conversaciones son JSON simple con el mismo formato que la versión para macOS, así que se pueden copiar de una a otra.

Compilar desde el código

Con el SDK de .NET 10 instalado:

```
dotnet build src\Citadel\Citadel.csproj -c Release
powershell -ExecutionPolicy Bypass -File scripts\build.ps1
```

El primer comando compila el programa. El segundo genera todo en `dist`: el `Citadel.exe` independiente, `citadel.msi` y `citadel-setup.exe`; el WiX Toolset 5 se descarga solo como paquete de NuGet. La versión se fija en un solo lugar, `src\Citadel\Citadel.csproj`, y los instaladores y la ventana Acerca de la leen de ahí.

El programa tiene dos modos para mantenimiento. Los dos aceptan `--data-folder <carpeta>` para usar otra carpeta en lugar de `%APPDATA%\Citadel`, así nunca tocan las conversaciones reales.

- `Citadel.exe --self-test --memory-folder <carpeta vacía>` prueba de punta a punta las funciones principales contra Ollama e imprime una línea PASS o FAIL por cada control: la lista de modelos, una respuesta sin Razonar y otra con Razonar, Detener, `/save` (archivo, línea del índice, sin marca de orden de bytes) y `/mem`. Se niega a correr sobre una carpeta de memorias en uso. Su salida se lee con `Start-Process Citadel.exe -ArgumentList ... -Wait -NoNewWindow -RedirectStandardOutput out.txt`.
- `Citadel.exe --screenshot <archivo.png> --window main|settings|about|save --language en|es` dibuja una ventana en una imagen y se cierra.

`scripts\screenshots.ps1 -Demo <carpeta>` genera las imágenes de `docs\images` con conversaciones y memorias de demostración, `scripts/manual.sh` (en macOS, con pandoc y Google Chrome) genera los manuales en PDF y `README.txt` y `README.es.txt` a partir de `README.md` y de este archivo, y `scripts/make-icon.sh` (en macOS) arma `src\Citadel\citadel.ico` a partir de `icon\citadel-1024.png`.

Carpeta	Contenido
`src/Citadel`	El programa.
`installer/Msi`	El paquete MSI (WiX).
`installer/SetupUI`	La ventana de instalación, en inglés y en español (.NET Framework 4.7.2, WPF).
`installer/Setup`	El programa de instalación que lleva la ventana y el MSI (paquete de WiX).
`scripts`	Compilación, imágenes, ícono y manuales.
`icon`	El ícono, en SVG y en PNG de 1024 píxeles.
`docs`	Manuales en PDF, imágenes y la hoja de estilo del manual.

Notas técnicas

- Las ventanas usan el tema Fluent de WPF (`Application.ThemeMode`), oscuro o claro según lo elegido, que .NET 10 todavía marca como experimental (advertencia WPF0001, silenciada en el archivo del proyecto). El color de énfasis es el que se elige en Ajustes → Apariencia (verde de fábrica).
- Las respuestas se muestran en un cuadro de texto enriquecido de solo lectura con un documento de flujo, así una respuesta entera se puede seleccionar y copiar. Los bloques de código son recuadros incrustados con su propio botón Copiar.
- Las respuestas llegan de `/api/chat` como un objeto JSON por línea. Detener cancela el pedido, lo que cierra la conexión; Ollama entonces cancela la generación, como muestra su registro (`srv stop: cancel task`). También se atienden los modelos que escriben su razonamiento entre etiquetas `<think>` en lugar de usar el campo `thinking`.
- En 15 preguntas difíciles de conteo, cuentas, lógica y fechas, hechas dos veces cada una, Qwen3 8B acertó 9 de 30 sin razonar y 26 de 30 razonando. Razonando, la respuesta mediana tardó 38 segundos y la más lenta 172, en una computadora donde el modelo escribe unos 17 tokens por segundo. A veces el modelo entra en un bucle de razonamiento hasta llegar al tope de 8.000 tokens; Detener lo corta.
- `/save` le pide al modelo un JSON (`"format": "json"`) sin razonar y con un tope de 3.000 tokens. Después Citadel pasa el nombre del archivo a minúsculas con guiones, reescribe la línea `_Updated` con la fecha y el modelo reales, y reemplaza la línea vieja del índice del mismo archivo en lugar de agregar otra.
- Ollama contesta con un error («does not support thinking») a un pedido con `"think": true` para un modelo sin esa capacidad. Citadel lee las capacidades en `/api/show` y a esos modelos les manda `"think": false`, esté como esté el botón Razonar.

- El túnel SSH corre `ssh -N` con `BatchMode=yes`, `ExitOnForwardFailure=yes` y señales de vida cada 15 segundos; Citadel espera a que el extremo local acepte conexiones antes de enviar. ssh.exe corre dentro de un objeto de trabajo que Windows cierra junto con Citadel, así que el túnel termina aunque Citadel se cierre a la fuerza.

Créditos

Citadel usa Ollama (licencia MIT) para correr los modelos, que se descargan aparte con sus propias licencias. Qwen3 lo publica el equipo de Qwen con licencia Apache 2.0. Los instaladores se arman con el WiX Toolset (licencia MS-RL).

Historial de versiones

Ver `CHANGELOG.md`.

Licencia

Copyright (C) 2026 Gabriel Castiglia.

Citadel es software libre: puedes redistribuirlo o modificarlo según los términos de la Licencia Pública General de GNU, solo la versión 2 (GPL-2.0-only), publicada por la Free Software Foundation. Se distribuye SIN NINGUNA GARANTÍA. El texto completo está en `LICENSE`.